

YOLOv8 기반 고성능 경량 플라스틱 폐기물 영상 세분화

조용우·이성도
서울과학고등학교

High Performance Lightweight Plastic Waste Segmentation with YOLOv8

Yongwoo Cho·Sungdo Lee
Seoul Science High School

국문 초록

플라스틱 재활용의 효율성을 높이기 위한 노력은 지속적으로 이루어지고 있으나, 재활용 플라스틱의 자동 정렬 및 분류 과정에서의 한계로 인해 많은 재활용 플라스틱이 적절히 처리되지 못하는 문제가 있다. 이러한 문제를 해결하기 위해 본 연구에서는 YOLOv8 기반의 고성능 경량 영상 세분화 모델을 개발하였다. (주)에코인에너지의 폐플라스틱 이미지 데이터를 사용하여, 모델이 실제 재활용 현장에서의 다양한 플라스틱 종류인 PET, PE, PP, PS를 정확하게 식별하고 분류하도록 훈련하였다. 결과적으로, 본 연구에서 개발된 모델은 기존 모델들보다 더 적은 계산 자원을 사용하면서도 더 높은 성능을 얻을 수 있었다. 재활용 플라스틱의 실시간 자동 정밀 분류는 플라스틱 폐기물 처리의 효율성을 높임으로써 환경 보호에 실질적인 도움이 될 것이다.

주제어: 플라스틱 재활용, 영상 세분화, YOLOv8, 경량 모델, 폐기물 처리

Abstract

Efforts to enhance the efficiency of plastic recycling are ongoing, but limitations in the automatic sorting and classification processes often result in inadequate processing of recyclable plastics. To address this issue, this study developed a high-performance, lightweight image segmentation model based on YOLOv8. Utilizing waste plastic image data from EcoEnergy, the model was trained to accurately identify and classify various types of plastics such as PET, PE, PP, and PS, commonly found in recycling environments. The developed model maintained high accuracy while using fewer computational resources compared to existing models. Precise classification of recyclable plastics is expected to increase the efficiency of waste plastic processing and significantly contribute to environmental protection.

Keywords: Plastic recycling, Image segmentation, YOLOv8, Lightweight model, Waste management.

I. 서론(Introduction)

1. 필요성과 목적

현대 사회에서 플라스틱 사용량의 급격한 증가는 폐기물 매립지의 포화를 가속화한다. 이렇게 쌓인 플라스틱 폐기물이 잔류하여 생태계에 악영향을 미치고 있다. 이 연구에서는 고성능의 경량화된 YOLOv8 기반 영상 세분화 모델을 개발하여 이 문제를 해결하고자 한다. 기존의 연구 중 근적외선(NIR)^[1] 분광법은 다양한 플라스틱의 화학적 조성에서 비롯되는 광학적 특성을 식별하여 정확한 분석이 가능하다는 장점이 있다. YOLOv8 모델은 고속 카메라와 결합하여 PET, PE, PP, PS와 같은 플라스틱을 식별하고 분류한다. 이 과정에서 선별된 플라스틱을 대상으로 NIR 분광법과 같은 광학적 테스트를 수행하여 폐기물 분류의 정확도를 높일 수 있는 기반을 마련할 뿐만 아니라, 기계 장치를 사용하여 폐기물을 분류하는 과정에서도 필수적이다. YOLOv8은 실시간 처리에 매우 적합하며, 일반적인 컴퓨팅 하드웨어로 처리가 가능하여 비용이 적게 드는 것뿐만 아니라 컨베이어 벨트 시스템에 적용하기에도 적절하다.

이 연구의 목적은 기존의 YOLOv4와 Mask-RCNN을 통해 훈련된 모델을, YOLOv8의 사용을 통해 성능과 파라미터 수에서 모두 증가하는 모델을 개발하는 것이다.

2. 선행 연구 및 관련 이론

2.1 : 기존 모델 분석

2.1.1 개체 감지 모델: YOLOv4

개체 감지(Object Detection)는 Bounding Box를 사용하여 개체의 위치와 카테고리를 파악하는 과정이다. 이 모델은 YOLOv4를 통한 단일 단계 객체 감지 방식을 채택하여 mAP(mean Average Precision)50에서, 정확도 93.4%라는 성능을 보여주며 총 60M(6000만 개) 파라미터로 구성되어 있다. YOLOv4는 CSPDarknet53을 백본 네트워크로 가지고 있으며 앵커 기반 접근 방식을 사용하여 다양한 크기의 객체를 탐지하는데 유리하다. YOLOv4 모델은 여태까지 자율주행 자동차와 보안 감시 분야에 널리 사용되었다.^[2]

2.1.2 영상 세분화 모델: Mask R-CNN

영상 세분화(Instance Segmentation)는 개체의 정확한 형태를 폴리곤으로 나타낸다. 이 모델은 YOLOv4를 통한 Bounding Box로 개체 위치를 감지한 이후 각 박스에 대해 영상 세분화를 진행하여 mAP50에서 정확도 84.1%를 기록한다.

2.2 : YOLOv8

YOLOv8는 YOLO(You Only Look Once) 시리즈의 최신 버전으로, 향상된 정확도와 속도를 제공한다. YOLOv4와의 주된 차이점은, Mixup 데이터 증강 기법과 코사인 애닐링 스케줄러를 사용하여 모델의 일반화 능력을 높이고 훈련 속도를 향상시켰다는 것이며, 앵커 프리 객체 검출 방식을 사용하여 객체의 크기에 유연하면서 빠르게 객체 탐지를 할 수 있다는 것이다.^[3]

2.2.1 Mixup 데이터 증강 기법

Mixup은 두 개의 이미지를 섞고, 이들의 라벨 또한 같은 비율로 섞는 데이터 증강 기법이다. 이 방법은 모델이 더 일반화된 특성을 학습할 수 있도록 도와주며, 과적합을 방지하는 데 유용하여 작은 데이터 셋에서 효과적이다.

Mixup은 두 개의 이미지를 랜덤하게 선택하여 가중 합을 구하고, 이와 동일한 비율로 두 이미지의 라벨을 혼합한다. 예를 들어, 이미지 A와 이미지 B를 선택하고, 0에서 1 사이의 가중치 λ 를 사용하여 새로운 이미지 C를 생성한다.^[4]

$$C = \lambda A + (1 - \lambda)B$$

$$Label_C = \lambda Label_A + (1 - \lambda)Label_B$$

수식 1 : Mixup 데이터 증강 기법

2.2.2 코사인 애닐링 스케줄러 (Cosine Annealing Scheduler)

코사인 애닐링 스케줄러는 학습률을 점진적으로 감소시키는 방법으로, 학습률은 학습이 진행됨에 따라 아래의 수식에 기반해 점차 감소해 모델의 안정적인 수렴을 돕는다. 아래 수식에서, η_t 는 현재 학습률, η_{\min} 과 η_{\max} 는 최소 및 최대 학습률, T_{cur} 은 현재 에포크, T_{\max} 는 최대 에포크이다.^[5]

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos(\frac{T_{cur}}{T_{\max}}\pi))$$

수식 2 : 코사인 애닐링 스케줄러

2.2.3 CSPDarknet53

CSPDarknet53은 YOLOv4와 YOLOv5, 그리고 YOLOv8에서 사용되는 백본 네트워크로, 원래의 Darknet53을 기반으로 하여 Cross Stage Partial (CSP) 네트워크가 추가된 버전이다.

CSP 구조는 레이어의 일부를 나누어 처리하고, 나중에 다시 결합하는 방식이다. 이를 통해 네트워크의 특성 정보를 더 효율적으로 학습할 수 있다. CSP 구조는 네트워크의 학습 능력을 향상시키고, 메모리 사용량을 줄이는 데 기여한다.^[6]

2.2.4 앵커 프리 객체 검출 VS 앵커 기반 객체 검출

앵커 기반 객체 검출은 사전에 정의된 다양한 크기와 비율의 앵커 박스를 사용하여 이미지 내 객체의 위치를 예측한다. 이러한 앵커 박스는 이미지의 각 그리드 셀에서 테스트되며, 객체의 위치와 크기를 조정하는 기준으로 사용된다. 이는 다양한 크기와 형태의 객체를 탐지하는 데 유리하지만, 앵커 박스를 적절하게 설정하는 과정이 복잡하고 계산 비용이 높을 수 있다.

반면, 앵커 프리 객체 검출은 사전 정의된 앵커 박스를 사용하지 않고, 이미지의 픽셀 또는 포인트를 직접 예측하여 객체의 위치를 결정한다. 예를 들어, 객체의 중심점이나 모서리 점을 예측하여 객체의 경계를 결정한다. 이 방식은 설정 과정이 단순하고 작은 객체나 비정형 객체를 더 잘 탐지할 수 있는 장점이 있다. 그러나 다양한 객체 크기와 형태를 다루기 위해 예측의 복잡성이 증가할 수 있다.

2.3 : 경계 상자와 영상 세분화 평가 지표

경계 상자와 영상 세분화를 평가하기 위해서 정밀도(Precision), 재현율(Recall), F1 점수(F1 Score) 및 평균 정확도(mAP)가 사용된다.

지표	개념	수식	의미
정밀도 (Precision)	참 양성 예측과 양성 예측 총 수의 비율	$p = \frac{TP}{TP + FP}$	양성 예측의 신뢰도
재현율 (Recall)	참 양성 예측과 실제 양성 총 수의 비율	$r = \frac{TP}{TP + FN}$	객체 인식률
F1 점수 (F1 Score)	정밀도와 재현율의 조화 평균	$f1 = \frac{2pr}{p + r}$	정밀도와 재현율 사이의 밸런스
mAP (mean Average Precision)	다양한 IoU 값에서의 Average Precision	$mAP = \text{mean}(AP \text{ across all classes and } IoU \text{ thresholds})$	전반적인 성능 지표
교차 비율 (IoU)	예측된 경계 상자와 실제 경계 상자의 겹치는 부분의 비율	$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}}$	예측된 경계 상자와 실제 경계 상자의 일치도

표 2 : 정밀도, 재현율, F1 점수, mAP, 교차 비율의 정의, 수식, 의미에 대한 표

II. 연구방법 및 이론(Method & Theory)

1. 도구 및 재료

본 연구에서는 YOLOv8 객체 감지 및 이미지 세분화 모델을 사용하였다. 연구에 사용된 주요 도구는 다음과 같다:

컴퓨팅 리소스 : NVIDIA TITAN Xp GPU, Intel(R) Xeon(R) Gold 6126 CPU, 93GB DDR4 2666 RAM을 탑재한 서버 컴퓨터.

소프트웨어 : Python 3.8.19, PyTorch 2.3.0, Ultralytics Environment

데이터셋 : 에코인에너지, AI hub, 페플라스틱 이미지 데이터, 각 이미지는 json형식으로 레이블링 됨.

2. 실험 과정

데이터 준비: 플라스틱 폐기물 이미지 데이터셋을 준비하고 전처리하였다. 각 플라스틱 종류당 5000개의 이미지를 512x512 사이즈로 변환하여 저장하였다. 이 과정에서 JSON 형식의 Segmentation Label 데이터를 변환하였으며, JSON에 오류가 발생한 경우 해당 파일을 삭제하였다. 이후 데이터를 검증(validation) 20%, 테스트(test) 10%, 훈련(train) 70%의 비율로 분할하였다.

모델 전이 학습: 사전 학습된 영상 분할 YOLOv8 모델 중 가장 경량화된 YOLOv8n_seg 모델을 초기 가중치로 설정하였다. 이후 GPU 메모리에 맞춰 Batch size를 10으로 설정하고, 약 1000에폭 동안 훈련하였다.

성능 평가: 테스트 데이터 셋을 사용하여 훈련된 모델을 평가하였다.

III. 결과(Data & Result)

이상치를 제거한 1991개의 데이터로 검증을 한 결과는 다음과 같다.

3.1 : 경계 상자 분석

3.1.1 경계 상자 수치 분석

	PET	PS	PP	PE	평균치
mAP50-95	0.990	0.993	0.995	0.995	0.993
정밀도 (precision)	1.000	1.000	1.000	1.000	1.000
재현율 (recall)	0.998	1.000	0.999	1.000	0.999
F1점수 (F1 score)	0.999	1.000	0.999	1.000	0.999

표 3 : PET, PS, PP, PE의 경계 상자에 대한 mAP50-95, 정밀도와 재현율, F1 점수의 표




그림 1 : 경계 상자의 플라스틱 분류별 mAP50-95, 재현율에 대한 그래프

데이터가 뚜렷한 차이를 나타내는 두 가지 항목 mAP50-95, 재현율 두 가지에 대해 [그림 1]의 그래프를 그려서 확인하였다. 두 그래프에서 PET는 mAP50-95와 재현율이 낮고 정밀도는 1인 것으로 보아, 존재하는 모든 PET를 검출하기 쉽지 않았다는 것을 알 수 있었다. 이는 [그림 2]에서 보이듯, 다른 플라스틱 종류에 비하여 투명한 PET가 배경색과 구분하기 어려워 상대적으로 더 낮은 성능을 보인 것으로 추정된다.

PS의 경우, 재현율은 높지만 경계상자의 mAP50-95가 그에 비해 못 미치는 결과를 보였는데, 이는 검은색 PS가 어두운 조명과 함께 검은 배경에서 사진이 찍혔을 때 검게 나오기 때문이라 추정된다. 그에 반해 PS의 재현율이 높은 까닭은 [그림 2]의 B에서 보이듯, 검은색 PS에 특징적인 문양이 있어서 그렇다고 추정할 수 있다.

PP의 경우 높은 경계 상자의 mAP50-95와 낮은 재현율을 보였는데, 이는 [그림 2]의 C에서 보이듯 PP가 가지는 다양한 색상과 질감, 그리고 검은색 PP와 검은색 배경으로 인해 구분이 잘 되지 않기 때문이라 추정된다.

PE는 특징적이며 일관적인 형태를 가지고 있어, mAP50-95와 재현율 모두에서 훌륭한 성능을 보였다.




그림 2 : A : PET 사진 데이터, B : PS 사진 데이터, C : PP 사진 데이터, D : PE 사진 데이터

3.1.2 경계 상자의 혼동 행렬 분석

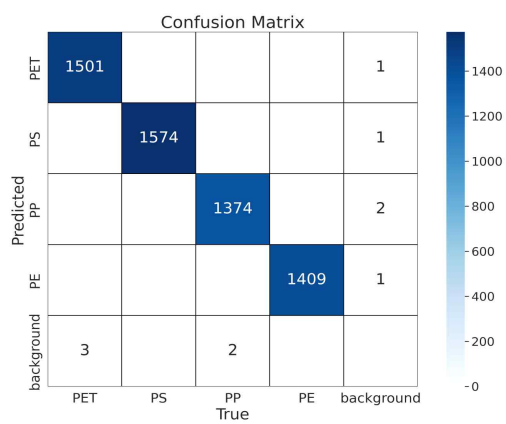


그림 3 : 경계 상자의 혼동 행렬

[그림 3]의 혼동 행렬(Confusion Matrix)에서는 모델이 몇 개의 PET와 PS를 배경으로 분류하였으며, 배경을 모든 플라스틱 종류로 한 번 이상 오판하였음을 알 수 있다. 따라서, 혼동 행렬에서 결과가 좋지 않았던 PET와 PP에 대해 배경으로 오판할 가능성이 높은 데이터를 증강시켜야 한다. 이를 위해 다양한 배경 상황에서 PET와 PP 샘플을 포함하는 데이터셋을 생성하여 모델의 분류 성능을 향상시킬 수 있다.

3.1.3 경계 상자 성능 그래프 종합 분석

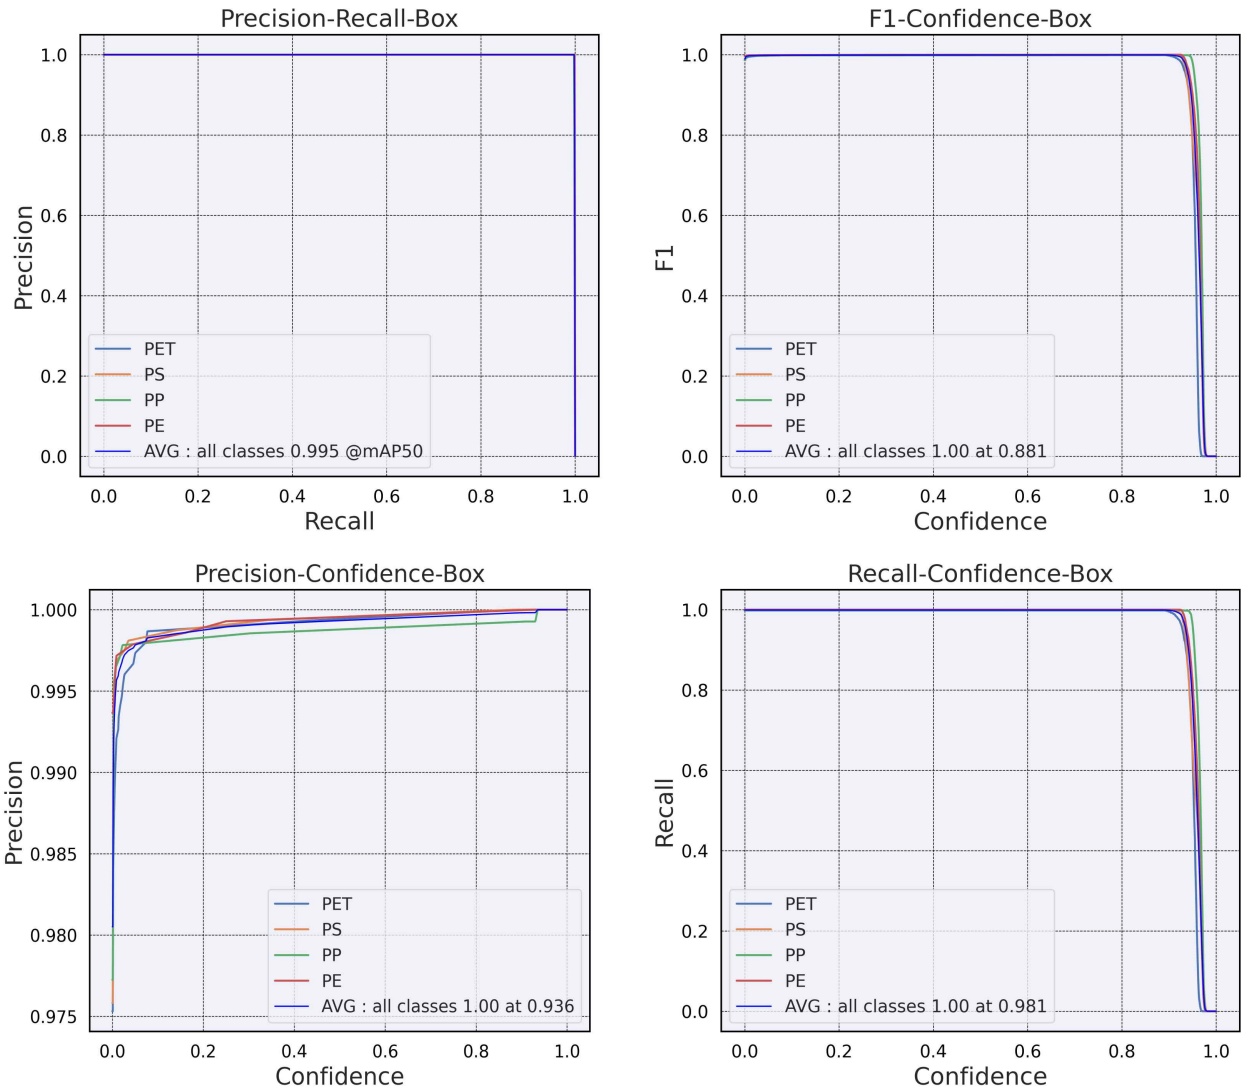


그림 4 : A : 경계 상자의 재현율에 대한 정밀도, B : 신뢰도 기준에 따른 F1 점수, C : 신뢰도 기준에 따른 정밀도, D : 신뢰도 기준에 따른 재현율

신뢰도 기준(Confidence)은 경계 상자를 특정 분류에 속하는지 판단하는 값이다. 해당 상자의 신뢰도가 기준값을 넘어야 특정 분류로 분류된다. [그림 4]의 A에서는 재현율에 관계없이 정밀도가 계속 기준 값을 상회하여 모델 훈련이 잘 되었음을 알 수 있다. [그림 4]의 B, C, D에서는 정밀도, 재현율, F1 점수가 잘 나오는 범위를 고려하여 적절한 신뢰도 기준을 정할 수 있다.

[그림 4]의 B에서는 신뢰도 0.881 이하에서 F1 점수가 1임을 알 수 있으며, C와 D에서는 각각 정밀도를 만족시키기 위해 신뢰도가 0.936 이상, 재현율을 만족시키기 위해 신뢰도가 0.981 이하여야 한다. 따라서 일반적으로 신뢰도 기준은 0.881에서 0.981 범위 내에서 설정할 수 있다. 그러나 거짓 양성 예측을 줄이는 것이 중요하다면(정밀도가 F1 점수보다 중요할 경우) 신뢰도 기준을 0.936에서 0.981 사이로 선택하는 것이 바람직하다.

모델 전반적으로 그래프가 높은 위치에 있는 것으로 보아, 신뢰도와 관계없이 매우 좋은 성능을 보인다. 또한, 플라스틱 종류에 관계없이 그래프가 일정하게 유지되어, 플라스틱 종류에 상관없이 균일하게 잘 학습되었음을 알 수 있다.

3.2 영상 세분화 분석

3.2.1 영상 세분화 수치 분석

	PET	PS	PP	PE	평균치
mAP50-95	0.973	0.978	0.994	0.988	0.984
정밀도 (precision)	1.000	1.000	1.000	1.000	1.000
재현율 (recall)	0.998	1.000	0.999	1.000	0.999
F1점수 (F1 score)	0.999	1.000	1.000	1.000	1.000

표 4 : PET, PS, PP, PE의 영상 세분화에 대한 mAP50-95, 정밀도와 재현율, F1 점수의 표


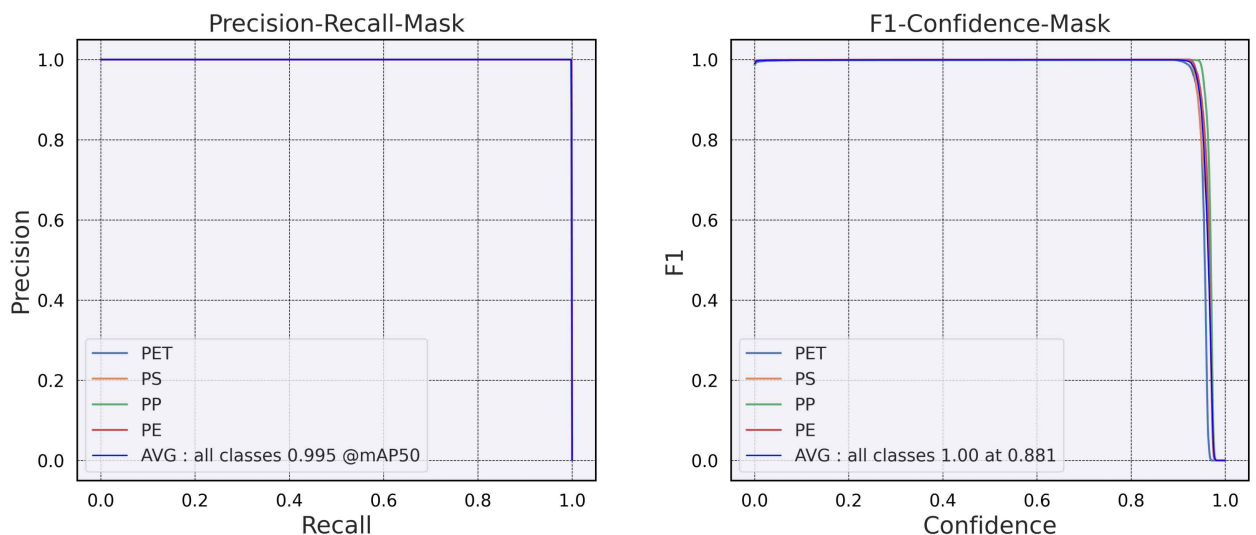


그림 5 : 영상 세분화에서의 A : mAP50-95, B : 재현율

영상 세분화에서는 경계 상자를 분류하는 것과 다르게, 이미지의 픽셀 단위로 분류를 진행한다. 따라서 모든 예측은 픽셀 단위로 수행된다. 영상 세분화에서는 대체로 경계 상자와 비슷한 양상이 나타나지만, PE에서 mAP50-95와 재현율의 관계는 다소 다르다. PE의 mAP50-95가 영상 세분화에서 플라스틱 종류 별 최고가 아닌 것으로 보아, 이는 PE의 경계 상자는 정확히 구할 수 있지만 영상 세분화의 정확도는 떨어진다는 것을 의미한다.

3.2.2 영상 세분화 성능 그래프 종합 분석



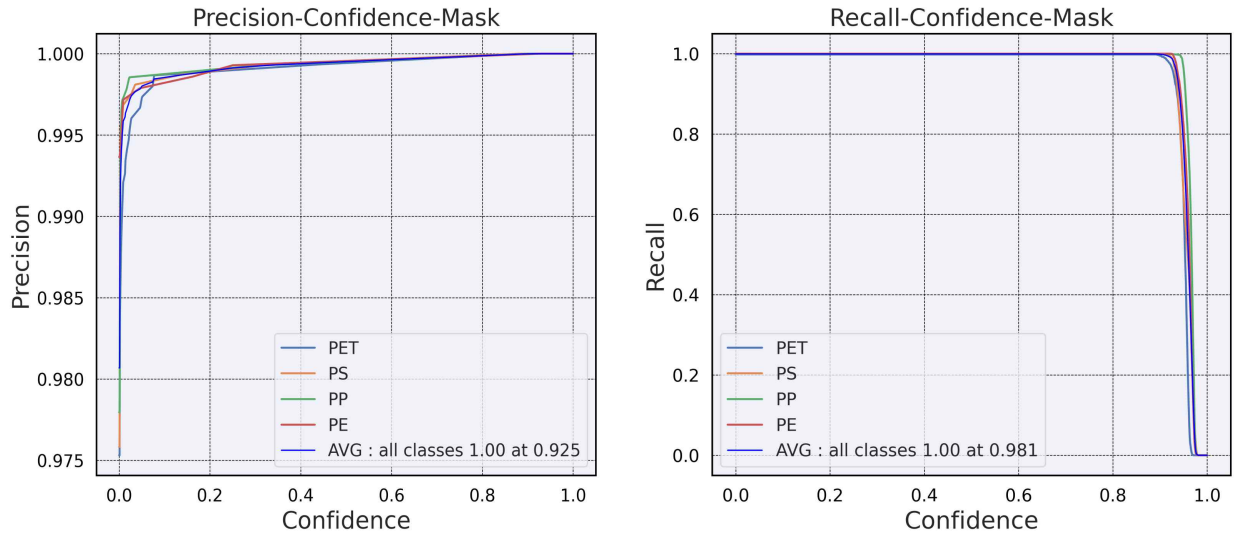


그림 6 : A : 영상 세분화의 재현율에 대한 정밀도, B : 신뢰도 기준에 따른 F1 점수, C : 신뢰도 기준에 따른 정밀도, D : 신뢰도 기준에 따른 재현율

[그림 6]에서는 [그림 4]와 매우 유사한 양상이 관찰된다. 신뢰도 기준 값은 [그림 6]의 B, 즉 F1 점수 기준으로는 0.881 이하, C (정밀도) 기준으로는 0.925 이상, D (재현율) 기준으로는 0.981 이하여야 한다는 것을 알 수 있다. 경계 상자의 경우에서 변경된 것은 정밀도에 대한 신뢰도 기준뿐이므로, 가능한 최적 신뢰도 기준의 범위는 경계 상자의 것과 유사하다. 또한, 경계 상자의 그래프와 유사하게 플라스틱 종류를 나누어 그렸음에도 불구하고 서로의 그래프가 밀접해 있으므로, 플라스틱 종류에 관계없이 고르게 학습되었음을 알 수 있다.


3.3 모델 추론 시간 (Inference Time) 분석

Format	Size (MB)	mAP50-95(영역 세분화)	Inference time (ms/im)
PyTorch	12.8	0.9743	6.56
TorchScript	12.9	0.9725	2.95

표 5 : 모델 변환 종류에 따른 모델 크기, mAP50-95, 추론 시간

TorchScript는 PyTorch의 최적화된 버전으로, 기존 모델을 단순화하여 더 빠르게 작동시키는 데 중점을 둔 변환 방식이다. 이렇게 최적화된 스크립트는 2.95ms/im의 작동 시간을 가지며, 이는 1초에 330장 이상의 이미지를 처리할 수 있는 속도이다. PyTorch 모델도 6.56ms/im의 추론 시간을 가진다. 실험을 진행한 컴퓨터의 사양은 위에 기재되어 있으며, 다른 프로세스가 실행되지 않는 상태에서 half=False로 설정하고 테스트 데이터를 사용하여 실험을 진행하였다.

실시간 처리에 있어 모델의 추론 시간을 줄이는 것은 매우 중요한 요소이다. 이러한 측면에서 모델의 파라미터 수를 6천만 개 이상에서 320만 개로 줄이고, 처리 속도를 3ms 내외로 줄인 것은 실시간 처리가 필수적인 재활용 처리 현장에 이 기술을 적용하는 데 큰 기여를 할 수 있다.



기존 모델과 현 모델을 대조하였을 때, 경계상자와 영상 세분화 모두에서 큰 성능 개선이 있었음을 알 수 있다. 기존 모델과 현재 모델의 mAP50으로 대조하였을 때, 경계상자의 mAP50은 6.1%, 영상 세분화의 mAP50은 13.3% 오른 것을 알 수 있다.

그림 7 : 기존 모델 VS 현 모델의 경계상자와 영역세분화 성능 대조

IV. 고찰(Discussion)

본 연구에서는 플라스틱 폐기물의 효율적인 분류를 위해 YOLOv8 모델을 사용하였다. 이 모델은 기존의 YOLOv4 및 Mask R-CNN 모델을 대체하여, 더 높은 정확도와 처리 속도를 제공함으로써 실시간 폐기물 분류가 가능하다는 가설을 바탕으로 실험을 설계하였다. 각 실험의 설계 근거는 기존 연구에서 나타난 파라미터 수와 성능의 한계점을 극복하고자 하는 목표에서 비롯되었다. 실험 결과의 분석 과정에서는 정밀도, 재현율과 처리 속도를 중점적으로 검토하였고, 이를 통해 모델의 성능을 평가하였다. 결과적으로, YOLOv8은 기대했던 성능 기준을 충족시키며, 연구 가설을 뒷받침하는 강력한 결과를 제공하였다.

V. 결론(Conclusion)

실험 결과, YOLOv8 모델은 기존 모델에 비해 플라스틱 폐기물 분류의 속도와 정확도를 모두 향상시켰다. 이 모델은 플라스틱 재활용 과정의 효율성을 높이는 데 중요한 역할을 할 수 있다. 본 연구는 플라스틱 폐기물 분류 문제에 대한 해결책을 제시하며, 향후 연구의 기초 자료로 활용될 수 있다.

VI. 제언(Proposal)

모델의 오분류에 대한 면밀한 분석을 통해 모델의 약점을 보완할 수 있는 방법을 모색하고 적용해야 한다. 현재 분석된 바로는 PET와 PP, 그리고 검은색과 투명한 플라스틱에 대한 약점 모음 추가 데이터를 통한 증강이 필요한 것으로 보인다. 또한, 현재 데이터에서 플라스틱의 개수나 위치 분포가 실제 상황에서 들어오는 폐기물 데이터와 차이가 있을 가능성이 크므로, 이러한 괴리를 줄이기 위해 직접 재활용 센터를 견학하고, 실제 생활에 적용 가능한 연구를 수행할 예정이다.

추가로, 재활용 폐기물 선별장에서의 효율적인 플라스틱 분류를 위해 로봇 손을 직접 설계하여 개발할 계획이다. 이 로봇 손은 기계적 설계와 인공지능 기술을 결합하여 플라스틱 폐기물을 더 정밀하고 빠르게 분류할 수 있도록 설계될 것이다. 이러한 통합 접근 방식은 플라스틱 재활용의 정확성과 효율성을 높여 지속 가능한 환경을 조성하는 데 중요한 역할을 할 것이다.

VII. 참고 문헌(Reference)

- [1] Kumagai, M., Suyama, H., Sato, T., Amano, T., & Ogawa, N. (2002). Discrimination of Plastics Using a Portable near Infrared Spectrometer. In Journal of Near Infrared Spectroscopy (Vol. 10, Issue 4, pp. 247-255). SAGE Publications. <https://doi.org/10.1255/jnirs.341>
- [2] Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection (Version 1). arXiv. <https://doi.org/10.48550/ARXIV.2004.10934>
- [3] Ultralytics. (2024, July 14). YOLOv8 architecture. Retrieved from <https://yolov8.org/yolov8-architecture/>
- [4] Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2017). mixup: Beyond Empirical Risk Minimization (Version 2). arXiv. <https://doi.org/10.48550/ARXIV.1710.09412>
- [5] Loshchilov, I., & Hutter, F. (2016). SGDR: Stochastic Gradient Descent with Warm Restarts (Version 5). arXiv. <https://doi.org/10.48550/ARXIV.1608.03983>
- [6] Wang, C.-Y., Liao, H.-Y. M., Yeh, I.-H., Wu, Y.-H., Chen, P.-Y., & Hsieh, J.-W. (2019). CSPNet: A New Backbone that can Enhance Learning Capability of CNN (Version 1). arXiv. <https://doi.org/10.48550/ARXIV.1911.11929>